

范海洋 | 资深数据仓库工程师

电话: 13611236008 / 邮箱: fanhy93@163.com / 工作年限: 8年

个人概述

- 8年数据仓库与大数据研发经验, 主导核心数据体系建设
- 主导企业级人力与财务主题域数据仓库0-1建设, 支撑高层决策分析
- 推动湖仓架构 (Iceberg) 与 OLAP 引擎 (StarRocks) 落地, 建设数据治理与权限体系
- 主导团队 AI Native 转型, 将 AI 引入研发全流程, 构建数据开发场景下的智能化工具体系

技术能力

数仓建模与架构

- Kimball 维度建模、分层架构设计, 具备复杂业务抽象与指标体系设计能力

大数据与性能优化

- Hive / Spark SQL / StarRocks, 具备数据倾斜治理、Join 优化与查询性能优化经验
- 熟悉 HDFS / Iceberg / Kafka / Flink 数据链路与数据接入

数据治理与AI工程

- 数据质量规则与权限管控体系建设经验, 支持高敏数据隔离与合规使用
- Python / Java / Shell, 用于数据处理与工程工具开发
- 基于 Prompt / MCP / Skills / Agent 构建数据研发效率工具, 沉淀元数据与血缘服务能力

工作经历

贝壳找房 | 资深数据仓库开发 / 技术负责人 | 2021.06-至今

职责

- 主导人力与财务主题域数据仓库从0到1建设, 参与多个S级战略项目的技术方案设计与落地
- 负责核心技术架构升级, 推动高密集群建设、数据入湖仓 (Iceberg) 与 OLAP 引擎 (StarRocks) 接入
- 负责团队技术规范与数据治理体系建设, 推行 AI Native 工作方式, 提升整体研发效率

360 | 大数据研发工程师 | 2018.06-2021.06

职责

- 主导安全数据仓库全面改造, 将原有 Hadoop Streaming 老流程升级为标准五层分层架构, 完成全流程数据开发
- 开发 Hive 扩展组件 (UDF / InputFormat / SerDe), 解决 EB 级安全日志非标格式解析需求
- 负责安全实体标签平台与事件预警平台建设, 支持多维度威胁数据自动预警

代表项目

公司级人力主题域数据仓库0-1建设（主题域负责人）

背景: 公司S级战略项目，覆盖招聘/员工/培训/薪酬/绩效/办公协同6个子主题; 覆盖15-20万员工全生命周期数据，支撑CHO/COO驾驶舱等高层级应用

技术挑战与方案

- **挑战1：多源数据整合与口径统一：**人力数据分散于招聘（北森/谷露）、薪酬等10+个业务系统；COE/HR/薪酬等多团队对同一指标各有独立口径，跨集市无法直接对比。
→制定统一接入规范，主导跨团队口径对齐会议，将各方计算逻辑收敛至单一权威口径。
- **挑战2：人员历史状态管理：**上游以时间轴区间存储员工和组织数据，历史数据存在修正场景，跨时点组织穿透实现复杂度极高。
→将时间轴按天展开为全量历史明细行，历史修正按员工维度重算覆写；任意时间点查询只需在最新分区按统计日期过滤，无需跨分区扫描，运维成本低。
- **挑战3：人力标签规则引擎：**业务圈选需求频繁变化，手写CASE WHEN每次需开发介入，迭代成本高响应慢。
→设计标签规则引擎，规则定义外置为JSON配置文件，引擎解析后调用UDF完成计算；新标签上线周期从数天缩短至当天，标签数量从数十扩展至百余个。

成果

- 构建公司级人力主题域数据模型（招聘/员工/培训/薪酬/绩效5大子主题），沉淀统一人员与组织维度，成为公司人力分析的统一数据底座。
- 支撑CHO/COO/CFO多个驾驶舱与报表系统，消除跨集市口径争议。

财务数据智能归因与AI解读平台（技术负责人）

背景: 面向1400+北京链家门店商圈经理，解决财务报表"看不懂、用不上"问题：月度报告打开率不足30%，财务答疑响应需2-3天

技术挑战与方案

- 挑战1：财务数据复杂性与AI理解准确性：**财务指标存在多层嵌套计算关系（如如净利率 = 净利润 / 营收, 净利润 = 毛利 - 费用），AI容易产生幻觉,给出错误的指标解读或归因分析，财务专家无法信任。
→与财务团队共建指标定义库与业务场景库作为知识底座；归因计算由确定性算法完成，AI 只负责将结果转化为业务语言；Prompt注入Few-shot 标准案例并明确约束"不推测"。
- 挑战2：报告格式一致性：**月度经营报告格式须稳定，LLM输出的随机性导致章节结构和数字呈现每次不一致。
→设计结构化中间层，LLM只输出JSON参数，Python模板渲染引擎固化报告结构；进一步将渲染封装为Skill，从工具层强制执行，彻底消除Agent跳过脚本的不稳定性。
- 挑战3：数据安全与权限控制：**财务数据敏感，AI对话存在跨区域越权查询风险。
→在MCP层基于用户角色做细粒度权限校验，建立审计日志与越权查询拦截机制，通过数据安全合规评审。

成果

- 完成端到端技术方案验证：数据层（Hive→StarRocks）+ 服务层（MCP）+ 应用层（AI Agent）全链路跑通
- 项目处于内部验证阶段，架构方案与归因算法已完成，待平台具备Skills编排能力后推广落地

360 EB级安全业务离线数仓建设（核心开发工程师）

背景: 日增TB级、总规模EB级安全数据（安全卫士/浏览器网盾日志+安全情报），500+张表;日志格式非标多样，标准Hive无法直接解析；老流程基于Hadoop Streaming，无分层架构

技术挑战与方案

- 挑战1：非标数据接入：**日志格式多样（多种自定义协议/嵌套结构），标准Hive无法直接解析，复杂计算逻辑重复开发严重。
→开发自定义InputFormat/SerDe适配多种日志格式，支持压缩自动识别、多行聚合与容错；封装10+通用UDF/UDTF（IP解析/UA解析/威胁情报匹配等），团队开发效率提升约30%。
- 挑战2：EB级性能优化：**百T级数据处理，作业运行时间长，存在严重数据倾斜。
→小文件合并减少Map任务数量；热点数据打散+两阶段聚合解决倾斜；ORC列式存储+Snappy压缩，存储成本降低50%。

成果

- 构建五层离线数仓体系，完成用户与服务端IP两个主题域建设
- 支撑安全威胁溯源、关联分析与实体标签生产场景

教育经历

中国科学院 | 研究生 | 2015-2018
吉林大学 | 本科 | 2011-2015